

Computational statistics

TP 3 : Hasting-Metropolis (and Gibbs) samplers

Thibault de SURREL

Exercice 1 : Hasting-Metropolis within Gibbs – Stochastic Approximation EM

1.

Les paramètres de notre modèle sont $\theta = (\bar{t}_0, \bar{v}_0, \sigma_\xi, \sigma_\tau, \sigma)$. Pour tout $i \in \llbracket 1, N \rrbracket$, on peut définir la variable aléatoire $z_i = (\alpha_i, \tau_i)$ dont les paramètres associés sont $\theta_i = (\sigma_\xi, \sigma_\tau, \sigma)$ et on peut définir $z_{pop} = (t_0, v_0)$ dont les paramètres associés sont $\theta_{pop} = (\bar{t}_0, \bar{v}_0)$. On cherche alors la log-vraisemblance de notre modèle $\log q(y, z, \theta)$. En utilisant deux fois la règle de Bayes, on peut déjà commencer par réécrire la log vraisemblance de la façon suivante :

$$\log q(y, z, \theta) = \log q(y \mid z, \theta) + \log q(z \mid \theta) + \log q(\theta).$$

On va alors calculer ces trois termes séparément :

— Pour $\log q(y \mid z, \theta)$, on commence par utiliser le fait que les $y_{i,j}$ sont tous indépendants :

$$\log q(y \mid z, \theta) = \sum_{i=1}^N \sum_{j=1}^{k_i} \log q(y_{i,j} \mid z, \theta)$$

Ensuite, sachant z et θ , on a que $y_{i,j} \sim \mathcal{N}(d_i(t_{i,j}), \sigma^2)$ donc

$$\log q(y \mid z, \theta) = \sum_{i=1}^N \sum_{j=1}^{k_i} \left[-\frac{1}{2} \left(\frac{y_{i,j} - d_i(t_{i,j})}{\sigma} \right)^2 - \log \sigma - \frac{1}{2} \log 2\pi \right]$$

— Pour $\log q(z \mid \theta)$, on commence par séparer par indépendance les $(z_i)_i$ et z_{pop} :

$$\log q(z \mid \theta) = \log q(z_{pop} \mid \theta_{pop}) + \log q(z_i \mid \theta_i)$$

Ensuite, on a d'une part que $t_0 \sim \mathcal{N}(\bar{t}_0, \sigma_{t_0}^2)$ et $v_0 \sim \mathcal{N}(\bar{v}_0, \sigma_{v_0}^2)$ et d'autre part que $\alpha_i \sim \log \mathcal{N}(0, \sigma_\xi^2)$ et $\tau_i \sim \mathcal{N}(0, \sigma_\tau^2)$ ainsi,

$$\begin{aligned} \log q(z \mid \theta) = & -\frac{1}{2} \left[\left(\frac{t_0 - \bar{t}_0}{\sigma_{t_0}} \right)^2 + \left(\frac{v_0 - \bar{v}_0}{\sigma_{v_0}} \right)^2 \right] - \log \sigma_{t_0} \sigma_{v_0} - \log 2\pi \\ & + \sum_{i=1}^N \left\{ -\frac{1}{2} \left[\left(\frac{\tau_i}{\sigma_\tau} \right)^2 + \left(\frac{\xi_i}{\sigma_\xi} \right)^2 \right] - \log \sigma_\tau \sigma_\xi - \log 2\pi \right\} \end{aligned} \quad (1)$$

— Enfin, pour $\log q(\theta)$ on sait que $\bar{t}_0 \sim \mathcal{N}(\bar{\bar{t}}_0, s_{t_0}^2)$, $\bar{v}_0 \sim \mathcal{N}(\bar{\bar{v}}_0, s_{v_0}^2)$ et que $\sigma_\xi^2 \sim \mathcal{W}^{-1}(v_\xi, m_\xi)$, $\sigma_\tau^2 \sim \mathcal{W}^{-1}(v_\tau, m_\tau)$ et $\sigma^2 \sim \mathcal{W}^{-1}(v, m)$ donc on a

$$\begin{aligned} \log q(\theta) = & -\frac{1}{2} \left(\frac{\bar{t}_0 - \bar{\bar{t}}_0}{s_{t_0}} \right)^2 - \frac{1}{2} \left(\frac{\bar{v}_0 - \bar{\bar{v}}_0}{s_{v_0}} \right)^2 - \log s_{t_0} s_{v_0} + \left(-(m_\xi + 2) \log \sigma_\xi - \frac{v_\xi^2}{2\sigma_\xi^2} \right) \\ & + \left(-(m_\tau + 2) \log \sigma_\tau - \frac{v_\tau^2}{2\sigma_\tau^2} \right) + \left(-(m + 2) \log \sigma - \frac{v^2}{2\sigma^2} \right) \end{aligned} \quad (2)$$

Ainsi, pour conclure, on a que

$$\begin{aligned} \log q(y, z, \theta) = & \sum_{i=1}^N \sum_{j=1}^{k_i} \left[-\frac{1}{2} \left(\frac{y_{i,j} - d_i(t_{i,j})}{\sigma} \right)^2 - \log \sigma - \frac{1}{2} \log 2\pi \right] - \frac{1}{2} \left[\left(\frac{t_0 - \bar{t}_0}{\sigma_{t_0}} \right)^2 + \left(\frac{v_0 - \bar{v}_0}{\sigma_{v_0}} \right)^2 \right] - \log \sigma_{t_0} \sigma_{v_0} \\ & - \log 2\pi + \sum_{i=1}^N -\frac{1}{2} \left[\left(\frac{\tau_i}{\sigma_\tau} \right)^2 + \left(\frac{\xi_i}{\sigma_\xi} \right)^2 \right] - \log \sigma_\tau \sigma_\xi - \log 2\pi - \frac{1}{2} \left(\frac{\bar{t}_0 - \bar{\bar{t}}_0}{s_{t_0}} \right)^2 - \frac{1}{2} \left(\frac{\bar{v}_0 - \bar{\bar{v}}_0}{s_{v_0}} \right)^2 \\ & - \log s_{t_0} s_{v_0} + \left(-(m_\xi + 2) \log \sigma_\xi - \frac{v_\xi^2}{2\sigma_\xi^2} \right) + \left(-(m_\tau + 2) \log \sigma_\tau - \frac{v_\tau^2}{2\sigma_\tau^2} \right) + \left(-(m + 2) \log \sigma - \frac{v^2}{2\sigma^2} \right). \end{aligned} \quad (3)$$

où j'ai mis en **rouge** les termes correspondant à la variable (y, z) et en **bleu** les termes correspondant aux paramètres θ . En effet, on veut maintenant montrer que le modèle appartient à une famille exponentielle courbe. Pour cela, on doit montrer qu'il existe $(y, z) \mapsto \phi_1(y, z), \theta \mapsto \phi_2(\theta), (y, z) \mapsto S(y, z)$ et $\theta \mapsto \psi(\theta)$ des fonctions telles que

$$\log q(y, z, \theta) = \phi_1(y, z) + \phi_2(\theta) + \langle S(y, z), \psi(\theta) \rangle + C.$$

où C est une constante indépendante de y, z et de θ .

Pour cela, on regarde chaque terme de $\log q$ comme ci-dessus :

— Pour $\log q(y | z, \theta)$, on voit que poser

$$S_1(y, z) = \frac{1}{NK} \sum_{i=1}^N \sum_{j=1}^{k_i} (y_{i,j} - d_i(t_{i,j}))^2 \text{ et } \psi_1(\theta) = -\frac{NK}{2\sigma^2}$$

convient où $K = \sum_{i=1}^N k_i$.

— Pour $\log q(z | \theta)$, on voit que l'on peut réécrire les différences au carré comme ci-dessous :

$$\left(\frac{t_0 - \bar{t}_0}{\sigma_{t_0}} \right)^2 = \frac{t_0^2 - 2t_0\bar{t}_0 + \bar{t}_0^2}{\sigma_{t_0}^2}$$

Ainsi, on pose

$$S_2(y, z) = t_0 \text{ et } \psi_2(\theta) = \frac{\bar{t}_0}{\sigma_{t_0}^2}$$

De même, on pose

$$S_3(y, z) = v_0 \text{ et } \psi_3(\theta) = \frac{\bar{v}_0}{\sigma_{v_0}^2}$$

Enfin, on pose aussi

$$S_4(y, z) = \frac{1}{N} \sum_{i=1}^N \tau_i^2 \text{ et } \psi_4(\theta) = -\frac{N}{2\sigma_\tau^2}$$

ainsi que

$$S_5(y, z) = \frac{1}{N} \sum_{i=1}^N \xi_i^2 \text{ et } \psi_5(\theta) = -\frac{N}{2\sigma_\xi^2}$$

Finalement, on pose :

$$S(y, z) = \begin{pmatrix} S_1(y, z) \\ S_2(y, z) \\ S_3(y, z) \\ S_4(y, z) \\ S_5(y, z) \end{pmatrix} \text{ et } \psi(\theta) = \begin{pmatrix} \psi_1(\theta) \\ \psi_2(\theta) \\ \psi_3(\theta) \\ \psi_4(\theta) \\ \psi_5(\theta) \end{pmatrix}$$

ainsi que

$$\begin{cases} \phi_1(y, z) = -\frac{t_0^2}{2\sigma_{t_0}^2} - \frac{v_0^2}{2\sigma_{v_0}^2} \\ \phi_2(\theta) = -NK \log \sigma - N \log \sigma_\tau \sigma_\xi - \frac{\bar{t}_0^2}{2\sigma_{t_0}^2} - \frac{\bar{v}_0^2}{2\sigma_{v_0}^2} + \log q(\theta) \end{cases} \quad (4)$$

on a le résultat. De plus, cette famille exponentielle est bien courbe car la dimension du paramètre θ est 5 ce qui est plus petit que la dimension de (y, z) qui vaut $2N + 2$.

3.

On cherche ici à générer des points selon la loi $\pi(z) = q(z | y, \theta)$ où $z = (z_{pop}, z_i)_{i \in \llbracket 1, N \rrbracket} = (t_0, v_0, \xi_i, \tau_i)_{i \in \llbracket 1, N \rrbracket}$. Commençons par noter la relation suivante, qui nous servira pour la suite, et qui utilise la relation de Bayes :

$$\pi(z) = q(z | y, \theta) = \frac{q(y | z, \theta)q(z | \theta)}{q(y | \theta)} \quad (5)$$

On choisit comme loi de proposition une gaussienne multivariée $\mathcal{N}(z, \sigma_{prop})$. Alors, cette loi étant symétrique, le ratio d'acceptation se réécrit $\alpha(z^{(k)}, z^*) = \min(1, \frac{\pi(z^*)}{\pi(z^{(k)})})$. Grâce à la relation 5, on peut réécrire le quotient de la façon suivante :

$$\frac{\pi(z^*)}{\pi(z^{(k)})} = \frac{q(z^* | y, \theta)}{q(z^{(k)} | y, \theta)} = \frac{q(y | z^*, \theta)q(z^* | \theta)}{q(y | z^{(k)}, \theta)q(z^{(k)} | \theta)}.$$

Afin de simplifier les calcul, on va s'intéresser au log de ce taux d'acceptation, la condition dans l'algorithme de Metropolis-Hasting se réécrivant alors : Si $U \sim \mathcal{U}([0, 1])$ alors on accepte z^* si $\log U \leq \log \alpha(z^{(k)}, z^*)$ et on garde $z^{(k)}$ sinon. Alors, on a

$$\log \alpha(z^{(k)}, z^*) = \min \left\{ 0, \log q(y | z^*, \theta) + \log q(z^* | \theta) - \log q(y | z^{(k)}, \theta) - \log q(z^{(k)} | \theta) \right\}.$$

De plus, on connaît déjà la quantité $\log q(y | z, \theta)$ d'après la question 1 :

$$\log q(y | z, \theta) = \sum_{i=1}^N \sum_{j=1}^{k_i} \left[-\frac{1}{2} \left(\frac{y_{i,j} - d_i(t_{i,j})}{\sigma} \right)^2 - \log \sigma - \frac{1}{2} \log 2\pi \right]$$

Dans cette formule, seule $d_{i,j}$ dépend de z , donc c'est le seul terme qui changera entre $\log q(y | z^*, \theta)$ et $\log q(y | z^{(k)}, \theta)$.

Pour le terme $\log q(z | \theta)$, on commence par utiliser l'indépendance de nos variables aléatoires selon i pour écrire :

$$\log q(z | \theta) = \log q(t_0 | \theta) + \log(v_0 | \theta) + \sum_{i=1}^N \log q(\xi_i | \theta) + \log q(\tau_i | \theta)$$

Toutes ces quantités sont connues d'après la question 1. On remarque qu'une partie des termes intervenant dans le calcul de $\log q(z | \theta)$ ne dépendent pas de z , (par exemple $\log \sigma_{t_0} \sigma_{v_0}$) et donc, d'après la formule de $\log \alpha$, seront éliminés lors de l'opération $\log q(z^* | \theta) - \log q(z^{(k)} | \theta)$.

On a alors tous les éléments pour implémenter l'algorithme de Symmetric Random Walk Hasting-Metropolis. La suite est sur le notebook.

4.

On cherche à calculer $\theta^{(k)} \in \operatorname{argmax}_{\theta \in \Theta} \{\phi_2(\theta) + \langle S_k, \psi(\theta) \rangle\}$ avec les notations de la question 1. Posons alors g la fonction telle que

$$\forall \theta \in \Theta, g(\theta) = \phi_2(\theta) + \langle S_k, \psi(\theta) \rangle = \phi_2(\theta) + \sum_{i=1}^5 S_k^{(i)} \psi_i(\theta).$$

où les $S^{(i)}$ sont les S_i de la question 1.

— **Pour** $\overline{t_0}$: On a dans un premier temps,

$$\frac{\partial \phi_2}{\partial \overline{t_0}}(\theta) = -\frac{\overline{t_0}}{\sigma_{t_0}^2} - \frac{\overline{t_0} - \overline{\overline{t_0}}}{s_{t_0}^2}$$

De plus, d'après les expressions des ψ_i , $\overline{t_0}$ n'intervient que dans ψ_2 donc :

$$\frac{\partial g}{\partial \overline{t_0}}(\theta) = -\frac{\overline{t_0}}{\sigma_{t_0}^2} - \frac{\overline{t_0} - \overline{\overline{t_0}}}{s_{t_0}^2} + S_k^{(2)} \frac{1}{\sigma_{t_0}^2}$$

Donc,

$$\frac{\partial g}{\partial \overline{t_0}}(\theta) = 0 \iff \overline{t_0}^{(k)} = \left(\frac{S_k^{(2)}}{\sigma_{t_0}^2} + \frac{\overline{\overline{t_0}}}{s_{t_0}^2} \right) \left(\frac{1}{\sigma_{t_0}^2} + \frac{1}{s_{t_0}^2} \right)^{-1}$$

Le calcul est le même pour $\overline{v_0}^{(k)}$.

— **Pour** σ_ξ : On a

$$\frac{\partial \phi_2}{\partial \sigma_\xi}(\theta) = -\frac{N}{\sigma_\xi} - \frac{(m_\xi + 2)}{\sigma_\xi} + \frac{v_\xi^2}{\sigma_\xi^3}$$

et σ_ξ n'intervient que dans l'expression de ψ_5 , ainsi :

$$\frac{\partial g}{\partial \sigma_\xi}(\theta) = -\frac{N}{\sigma_\xi} - \frac{(m_\xi + 2)}{\sigma_\xi} + \frac{v_\xi^2}{\sigma_\xi^3} + S_k^{(5)} \frac{N}{\sigma_\xi^3}$$

Ce qui permet de dire que

$$\frac{\partial g}{\partial \sigma_\xi}(\theta) = 0 \iff \sigma_\xi^{(k)} = \sqrt{\frac{S_k^{(5)} N + v_\xi^2}{N + m_\xi + 2}}$$

Les calculs sont les mêmes (à un facteur K près pour σ) pour trouver $\sigma^{(k)}$ et $\sigma_\tau^{(k)}$

Ainsi, on peut résumer ces calculs en donnant l'expression complète de $\theta^{(k)}$:

$$\theta^{(k)} = \begin{pmatrix} \overline{t_0}^{(k)} \\ \overline{v_0}^{(k)} \\ \sigma_\xi^{(k)} \\ \sigma_\tau^{(k)} \\ \sigma^{(k)} \end{pmatrix} = \begin{pmatrix} \left(\frac{S_k^{(2)}}{\sigma_{t_0}^2} + \frac{\overline{\overline{t_0}}}{s_{t_0}^2} \right) \left(\frac{1}{\sigma_{t_0}^2} + \frac{1}{s_{t_0}^2} \right)^{-1} \\ \left(\frac{S_k^{(3)}}{\sigma_{v_0}^2} + \frac{\overline{\overline{v_0}}}{s_{v_0}^2} \right) \left(\frac{1}{\sigma_{v_0}^2} + \frac{1}{s_{v_0}^2} \right)^{-1} \\ \sqrt{\frac{S_k^{(5)} N + v_\xi^2}{N + m_\xi + 2}} \\ \sqrt{\frac{S_k^{(4)} N + v_\tau^2}{N + m_\tau + 2}} \\ \sqrt{\frac{S_k^{(1)} K N + v^2}{K N + m + 2}} \end{pmatrix}$$

5./6./7.

Sur le notebook.

8.

L'avantage d'échantillonner des blocs de variables au lieu de les échantillonner une par une est un gain de temps en diminuant le nombre de tirages à faire. Cette méthode est utile lorsque les éléments à échantillonner comportent des variables qui sont corrélées entre elles, comme ici c'est le cas pour les z_{pop} et les z_i qui forment $N + 1$ blocs de variables corrélées.

9.

Sur le notebook.

Exercice 2 : Multiplicative Hasting-Metropolis

1.

On cherche à déterminer la distribution de $Y \sim q(X, Y)$. Pour cela, on se munit d'une fonction h continue bornée. On a alors,

$$\begin{aligned}\mathbb{E}[h(Y)] &= \mathbb{E}[h(\varepsilon X) \mid \mathcal{B} = 0] \mathbb{P}(\mathcal{B} = 0) + \mathbb{E}\left[h\left(\frac{X}{\varepsilon}\right) \mid \mathcal{B} = 1\right] \mathbb{P}(\mathcal{B} = 1) \\ &= \frac{1}{2} \int_{-1}^1 h(\varepsilon X) f(\varepsilon) d\varepsilon + \frac{1}{2} \int_{-1}^1 h\left(\frac{X}{\varepsilon}\right) f(\varepsilon) d\varepsilon\end{aligned}\quad (6)$$

Car \mathcal{B} suit une loi de Bernoulli de paramètre $\frac{1}{2}$.

— Cas $X > 0$, alors, on effectue le changement de variable affine $y = \varepsilon X$ dans la première intégrale de 6 qui nous donne :

$$\int_{-1}^1 h(\varepsilon X) f(\varepsilon) d\varepsilon = \int_{-X}^X h(y) \frac{f(\frac{y}{X})}{X} dy$$

De plus, on effectue le changement de variable $y = \frac{X}{\varepsilon}$ dans la deuxième intégrale qui nous donne :

$$\begin{aligned}\int_{-1}^1 h\left(\frac{X}{\varepsilon}\right) f(\varepsilon) d\varepsilon &= \int_{-1}^0 h\left(\frac{X}{\varepsilon}\right) f(\varepsilon) d\varepsilon + \int_0^1 h\left(\frac{X}{\varepsilon}\right) f(\varepsilon) d\varepsilon \\ &= \int_{-X}^{-\infty} h(y) f\left(\frac{X}{y}\right) \left(-\frac{X}{y^2}\right) dy + \int_{+\infty}^X h(y) f\left(\frac{X}{y}\right) \left(-\frac{X}{y^2}\right) dy \\ &= \int_{-\infty}^{-X} h(y) f\left(\frac{X}{y}\right) \frac{X}{y^2} dy + \int_X^{+\infty} h(y) f\left(\frac{X}{y}\right) \frac{X}{y^2} dy\end{aligned}\quad (7)$$

On peut effectuer le même calcul dans le cas $X < 0$ ce qui permet de dire, dans le cas où $X \neq 0$, on a :

$$\begin{aligned}q(X, Y) &= \frac{1}{2} \frac{f(\frac{Y}{X})}{|X|} \mathbb{1}_{-|X|, |X|}[Y] + \frac{1}{2} f\left(\frac{X}{Y}\right) \frac{|X|}{Y^2} \mathbb{1}_{]-\infty, -|X|} + \frac{1}{2} f\left(\frac{X}{Y}\right) \frac{|X|}{Y^2} \mathbb{1}_{|X|, +\infty}[\\ &= \frac{1}{2} \frac{f(\frac{Y}{X})}{|X|} \mathbb{1}_{|Y| \leq |X|} + \frac{1}{2} f\left(\frac{X}{Y}\right) \frac{|X|}{Y^2} \mathbb{1}_{|Y| > |X|}\end{aligned}\quad (8)$$

— Dans le cas où $X = 0$, alors $Y = 0$ donc

$$q(0, Y) = \delta_0$$

On considère dans la suite que X ne prend jamais la valeur 0.

2.

Le taux d'acceptation α est par définition :

$$\alpha(x, y) = \min\left(1, \frac{\pi(y)q(y, x)}{\pi(x)q(x, y)}\right)$$

Dans notre cas, et compte tenu de la densité q calculée à la question 1, nous avons :

$$\begin{aligned}\frac{\pi(y)q(y, x)}{\pi(x)q(x, y)} &= \frac{\frac{1}{2} \frac{f(\frac{x}{y})}{|y|} \mathbb{1}_{|x| \leq |y|} + \frac{1}{2} f\left(\frac{y}{x}\right) \frac{|y|}{x^2} \mathbb{1}_{|x| > |y|}}{\frac{1}{2} \frac{f(\frac{y}{x})}{|x|} \mathbb{1}_{|y| \leq |x|} + \frac{1}{2} f\left(\frac{x}{y}\right) \frac{|x|}{y^2} \mathbb{1}_{|y| > |x|}} \\ &= \frac{|y| \frac{1}{2} \frac{f(\frac{y}{x})}{|x|} \mathbb{1}_{|y| \leq |x|} + \frac{1}{2} f\left(\frac{x}{y}\right) \frac{|x|}{y^2} \mathbb{1}_{|y| > |x|}}{|x| \frac{1}{2} \frac{f(\frac{y}{x})}{|x|} \mathbb{1}_{|y| \leq |x|} + \frac{1}{2} f\left(\frac{x}{y}\right) \frac{|x|}{y^2} \mathbb{1}_{|y| > |x|}} \\ &= \frac{|y|}{|x|}\end{aligned}\quad (9)$$

Ainsi, le taux d'acceptation est :

$$\alpha(x, y) = \min\left(1, \frac{\pi(y)|y|}{\pi(x)|x|}\right)$$

3.

Pour la première distribution que l'on souhaite échantillonner, on choisit la loi exponentielle $\mathcal{E}(1)$ car elle est échantillonnable par la méthode de la transformée inverse. On choisit f comme étant la distribution uniforme sur $] - 1, 1[: \mathcal{U}] - 1, 1[$.

Les résultats (comparaison des densités et des quantiles) montrent que l'on arrive bien à estimer cette loi $\mathcal{E}(1)$. On notera tout de même sur le qq-plot que notre méthode a tendance à donner plus souvent des échantillons de grandes valeurs que ce que la vraie loi $\mathcal{E}(1)$ ferait.

Pour la deuxième loi à échantillonner, on prend une $\mathcal{N}(0, 1)$. Cette fois aussi, on arrive très bien à l'échantillonner, et les quantiles estimés sont extrêmement proches des quantiles théoriques. On peut donc valider notre méthode.

Exercice 3 : Data augmentation

1.

On commence par montrer que le processus $\{(X_n, Y_n), n \geq 0\}$ est une chaîne de Markov. Pour cela, on considère la filtration canoniquement associée à ce processus : $(\mathcal{F}_n = \sigma(X_0, Y_0, \dots, X_n, Y_n)_{n \in \mathbb{N}})$. On note $\mathcal{B}(\mathbb{R}^p \times \mathbb{R}^q)$ l'ensemble des boréliens de $\mathbb{R}^p \times \mathbb{R}^q$, alors on a $\mathcal{B}(\mathbb{R}^p \times \mathbb{R}^q) = \mathcal{B}(\mathbb{R}^p) \otimes \mathcal{B}(\mathbb{R}^q)$, c'est-à-dire que pour $A \in \mathcal{B}(\mathbb{R}^p \times \mathbb{R}^q)$, on a $A = A_1 \times A_2$, avec $A_1 \in \mathcal{B}(\mathbb{R}^p)$ et $A_2 \in \mathcal{B}(\mathbb{R}^q)$.

Soit $A \in \mathcal{B}(\mathbb{R}^p \times \mathbb{R}^q)$, alors

$$\begin{aligned} \mathbb{P}((X_{n+1}, Y_{n+1}) \in A \mid \mathcal{F}_n) &= \mathbb{P}(X_{n+1} \in A_1, Y_{n+1} \in A_2 \mid \mathcal{F}_n) \\ &= \mathbb{P}(X_{n+1} \in A_1 \mid \mathcal{F}_n) \mathbb{P}(Y_{n+1} \in A_2 \mid \mathcal{F}_n, X_{n+1}) \text{ d'après la formule de Bayes,} \\ &= \left(\int_{A_1} f_{X|Y}(x, Y_n) dx \right) \left(\int_{A_2} f_{Y|X}(X_{n+1}, y) dy \right) \\ &= \mathbb{P}(X_{n+1} \in A_1 \mid X_n, Y_n) \mathbb{P}(Y_{n+1} \in A_2 \mid X_{n+1}, X_n, Y_n) \\ &= \mathbb{P}(X_{n+1} \in A_1, Y_{n+1} \in A_2 \mid X_n, Y_n) \end{aligned} \quad (10)$$

Ainsi, $\{(X_n, Y_n), n \geq 0\}$ est une chaîne de Markov.

De plus, en reprenant la 3ème ligne de l'équation 10, on a que

$$\begin{aligned} \mathbb{P}((X_n, Y_n) \in A \mid (X_{n-1}, Y_{n-1})) &= \left(\int_{A_1} f_{X|Y}(x, Y_{n-1}) dx \right) \left(\int_{A_2} f_{Y|X}(X_n, y) dy \right) \\ &= \int_{A_1 \times A_2} f_{X|Y}(x, Y_{n-1}) f_{Y|X}(x, y) dx dy \end{aligned} \quad (11)$$

d'après le théorème de Fubini-Tonelli car les densités sont positives. On a ainsi l'expression du noyau de transition de la chaîne de Markov.

2.

Montrons que le processus $(Y_n)_{n \in \mathbb{N}}$ est une chaîne de Markov. On considère dans cette question que $(\mathcal{F}_n)_{n \in \mathbb{N}}$ est la filtration canoniquement associée au processus $(Y_n)_{n \in \mathbb{N}}$. Soit $A \in \mathcal{B}(\mathbb{R}^q)$, alors on a

$$\begin{aligned} \mathbb{P}(Y_{n+1} \in A \mid \mathcal{F}_n) &= \int_A f_{Y|X}(X_{n+1}, y) dy \\ &= \int_{\mathbb{R}^p} f_{X|Y}(x, Y_n) \left(\int_A f_{Y|X}(x, y) dy \right) dx \\ &= \int_{\mathbb{R}^p} \int_A f_{X|Y}(x, Y_n) f_{Y|X}(x, y) dy dx \quad \text{par le théorème de Fubini-Tonelli} \\ &= \int_A \left(\int_{\mathbb{R}^p} f_{X|Y}(x, Y_n) f_{Y|X}(x, y) dx \right) dy \quad \text{encore par le théorème de Fubini-Tonelli} \\ &= \mathbb{P}(Y_{n+1} \in A \mid Y_n) \end{aligned} \quad (12)$$

Ainsi, $(Y_n)_{n \in \mathbb{N}}$ est bien une chaîne de Markov et son noyau de transition est :

$$P(y, A) = \int_A \left(\int_{\mathbb{R}^p} f_{X|Y}(x, y) f_{Y|X}(x, z) dx \right) dz$$

3.

On considère maintenant la fonction de densité f définie par

$$\forall (x, y) \in \mathbb{R}^2, f(x, y) = \frac{4}{\sqrt{2\pi}} y^{3/2} \exp \left[-y \left(\frac{x^2}{2} + 2 \right) \right] \mathbb{1}_{\mathbb{R}^+}(y)$$

On commence par calculer les densités marginales f_X et f_Y .

— Pour f_X ,

$$f_X(x) = \int_{\mathbb{R}} f(x, y) dy = \frac{4}{\sqrt{2\pi}} \int_0^{+\infty} \exp \left[-y \left(\frac{x^2}{2} + 2 \right) \right]$$

On effectue un changement de variable affine $u = y \left(\frac{x^2}{2} + 2 \right)$ ce qui nous donne,

$$f_X(x) = \frac{4}{\sqrt{2\pi}} \frac{1}{\frac{x^2}{2} + 2} \int_0^{+\infty} \left(\frac{1}{\frac{x^2}{2} + 2} u \right)^{3/2} \exp(-u) du = \frac{4}{\sqrt{2\pi}} \frac{1}{(\frac{x^2}{2} + 2)^{5/2}} \int_0^{+\infty} u^{3/2} \exp(-u)$$

Ainsi, on a

$$f_X(x) = \frac{4}{\sqrt{2\pi}} \frac{\Gamma\left(\frac{5}{2}\right)}{(\frac{x^2}{2} + 2)^{5/2}}$$

— Pour f_Y ,

$$f_Y(y) = \int_{\mathbb{R}} f(x, y) dx = \frac{4}{\sqrt{2\pi}} y^{3/2} e^{-2y} \mathbb{1}_{\mathbb{R}^+}(y) \int_{\mathbb{R}} \exp\left(-y \frac{x^2}{2}\right) dx$$

Par le changement de variable affine $u = \sqrt{y}x$, on retrouve l'intégrale de Gauss :

$$f_Y(y) = \frac{4}{\sqrt{2\pi}} y^{3/2} e^{-2y} \mathbb{1}_{\mathbb{R}^+}(y) \int_{\mathbb{R}} \frac{1}{\sqrt{y}} \exp\left(-\frac{u^2}{2}\right) du = 4y e^{-2y} \mathbb{1}_{\mathbb{R}^+}(y)$$

On peut maintenant donner les densités conditionnelles $f_{X|Y}$ et $f_{Y|X}$:

$$\begin{aligned} f_{X|Y}(x, y) &= \frac{f(x, y)}{f_Y(y)} = \frac{1}{\sqrt{2\pi}} \sqrt{y} \exp \left(-y \frac{x^2}{2} \right) \mathbb{1}_{\mathbb{R}^+}(y) \\ f_{Y|X}(x, y) &= \frac{f(x, y)}{f_X(x)} = \frac{\left(\frac{x^2}{2} + 2 \right)^{5/2}}{\Gamma\left(\frac{5}{2}\right)} y^{3/2} \exp \left[-y \left(\frac{x^2}{2} + 2 \right) \right] \mathbb{1}_{\mathbb{R}^+}(y) \end{aligned} \tag{13}$$

Ainsi, $X_n | Y_{n-1} \sim \mathcal{N}\left(0, \frac{1}{\sqrt{Y_{n-1}}}\right)$ et $Y_n | X_n \sim \Gamma\left(\frac{5}{2}, \frac{X_n^2}{2} + 2\right)$.

4.

Soit H une fonction bornée. On cherche à calculer

$$I = \int_{\mathbb{R}} \frac{H(x)}{(4 + x^2)^{5/2}} dx.$$

On peut utiliser l'échantillonneur de Gibbs des questions précédentes pour estimer l'intégrale I . En effet, on peut réécrire

$$I = \frac{1}{2^{5/2}} \int_{\mathbb{R}} \frac{H(x)}{(2 + \frac{x^2}{2})^{5/2}} dx = \frac{\sqrt{2\pi}}{4\Gamma\left(\frac{5}{2}\right) 2^{5/2}} \mathbb{E}[H(X)]$$

où $X \sim f_X$. On peut donc simuler une suite $(X_n)_{n \in \mathbb{N}}$ grâce à l'algorithme précédent et ensuite utiliser un estimateur de Monte-Carlo :

$$I \approx \frac{\sqrt{2\pi}}{4\Gamma\left(\frac{5}{2}\right) 2^{5/2}} \frac{1}{n} \sum_{k=0}^n H(X_k)$$